UNIVERSIDAD DEL VALLE DE GUATEMALA
CC3092 - Deep Learning y Sistemas Inteligentes
Sección 20
Javier Fong



Laboratorio 9
Series de tiempo y forecasting

Reporte grupal

Fernando Andree Hernández Martínez 23645
Fernando José Rueda Rodas 23748

GUATEMALA
30 de octubre de 2026

1. Investigación: herramientas para forecasting

nn.LSTM/nn.GRU (`input_size`, `hidden_size`, `num_layers`, `batch_first`, `dropout` entre capas): devuelven `output` (B,L,H) con el estado de la última capa en cada paso, `h_n` (capas, B,H) con el último estado de cada capa y, solo la LSTM, `c_n` con la celda de memoria. **nn.Conv1d causal**: `Conv1d(in,out,k,dilation=d)` con relleno solo a la izquierda de $(k-1)d$; con bloques de dilatación d_b el campo receptivo es $R = 1 + \sum_b (k-1)d_b$ (nuestra TCN: $k=2$, $d = 1 \dots 128$, $R = 256 > L$). **nn.TransformerEncoderLayer** (`d_model`, `nhead`, `dim_feedforward`): la atención es invariante a permutaciones, por eso se *suma* una codificación posicional (senoidal o `nn.Embedding`) al embedding. PatchTST tokeniza parches de 24 h por canal; iTransformer usa cada serie completa como token. **Nixtla**: formato largo `(unique_id, ds, y)`; `cross_validation(h, n_windows, step_size, refit)` hace origen móvil (usamos 92 ventanas, paso 24; `refit=False` entrena una vez). **Chronos-Bolt** `predict_quantiles(inputs, prediction_length, quantile_levels)`: contexto ($B,T \leq 2048$), devuelve cuantiles (B,H,Q) y media. **Local vs. global**: un modelo por serie frente a uno compartido que transfiere patrones. **Teacher forcing**: alimentar el valor real anterior al entrenar; acelera, pero genera *exposure bias*. **RevIN**: normaliza cada ventana con su media/desviación y desnormaliza la salida, absorbiendo cambios de nivel. **Pinball**: $\rho_q(e) = \max(qe, (q-1)e)$, cuyo minimizador es el cuantil q. **MASE** escala el MAE por cliente con el seasonal naive in-sample ($m = 24$) y promedia clientes; **WAPE** $= \sum|e| / \sum|y|$ pondera por volumen.

2. Preparación de la serie y auditoría de fugas

Panel. 15 min → kWh por hora ($\sum$kW·0.25). Con el filtro "sin rachas de ceros $>$ 24 h en 2012–2014" quedan **314 de 370 clientes**, con 26,304 h cada uno (8.26 M observaciones). Por cómputo usamos **100 clientes** con semilla 42 (2.63 M), los mismos para todos los modelos. **Cambio de horario:** los registros 01:00–01:45 vienen en 0 en marzo (se imputa la media de 00:00 y 02:00) y doblados en octubre (se dividen entre 2). **Exploración:** doble estacionalidad, diaria (valle de 2 a 6 h, pico nocturno) y semanal (domingo y feriados bajos). El 25 de diciembre el consumo cae 36–54 % y el 1 de enero 35–37 %. **Escalas:** el consumo medio va de 20.9 a 11,480 kWh/h (mediana 159.5), es decir 550×. Por eso usamos **z-score por cliente** con estadísticos de entrenamiento: la normalización global dio MASE 1.17 (DLinear) y 1.75 (LSTM), y la de ventana (RevIN) 0.887, casi igual que por serie (0.883). **Calendario:** hora, día y mes en seno/coseno (2 columnas cada uno, circulares), más feriado PT y fin de semana binarios. **Dataset** ($L = 168$, $H = 24$, stride 1): **2,169,700** ventanas de entrenamiento, **218,500** de validación y **218,500** de prueba. Además, 92 orígenes diarios por bloque para el backtest.

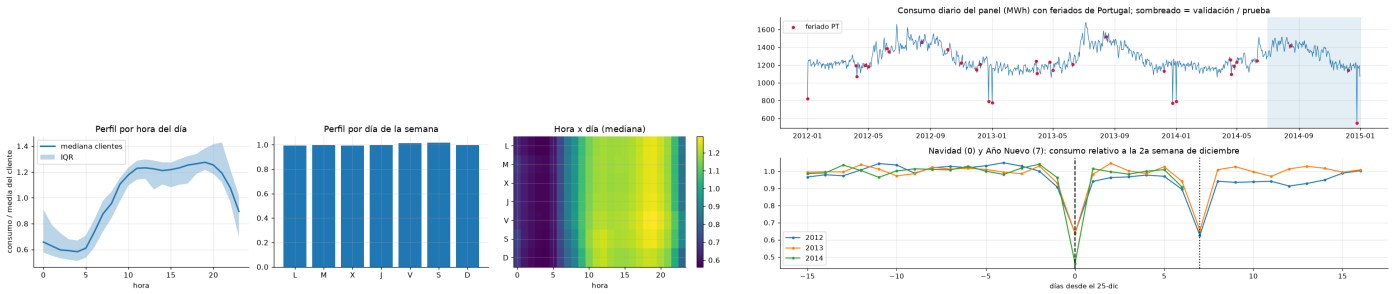


Figura 1: Izq.: perfil relativo por hora, por día y mapa hora×día. Der.: consumo diario del panel con feriados de Portugal y caída en Navidad (0) y Año Nuevo (7).

Auditoría de fugas (código en el notebook, sección 2.3): (1) *Split aleatorio*: los bloques son cronológicos; el último objetivo de entrenamiento es el 30-jun 23:00 y el primero de validación el 1-jul 00:00. Solo se baraja dentro de entrenamiento. (2) *Escalar con toda la serie*: μ, σ se ajustan con `Y[:t_train_end]` (`assert`). Las librerías reciben los datos ya normalizados así. (3) *Early stopping con prueba*: el criterio es el MASE de los 92 orígenes de julio a septiembre, cuyo último horizonte termina antes del 1-oct. (4) *Covariables*: X termina a las 23:00 del día anterior y X_{fut} solo contiene calendario del día pronosticado. Además, `backtest()` entrega a cada modelo `Y[:t0]`, y una prueba de "futuro alterado" verifica que el pronóstico no cambia.

3. Protocolo y métricas

Una función `backtest(modelo)`: 92 orígenes (00:00 de cada día de oct–dic 2014). En cada uno, el modelo recibe solo los datos hasta las 23:00 previas y pronostica 24 h. Los pesos se entrenan una vez con datos hasta el 30-sep (validación para early stopping). Todo modelo de librería se envuelve con la misma interfaz `forecast(hist, t0)`. Las métricas se calculan en kWh sobre clientes y orígenes: MAE, RMSE (también por cliente, `metrics_by_client.csv`), WAPE, MAPE y MASE. El **MAPE** excluye las horas con $y = 0$ (división indefinida). Con valores cercanos a cero un error pequeño en kWh se vuelve de cientos por ciento: el percentil 99 del APE es 83 % frente a una mediana por cliente de 9.6 %.

4. Iteraciones (validación) y estrategias multi-paso

Cuadro 1: Iteraciones principales: MASE de validación (pérdida L1, AdamW, early stopping). Las curvas por epoch, los parámetros, los tiempos y la memoria pico de las 42 iteraciones están en `iterations.csv` y `epoch_logs.csv`.

Grupo	Variación	DLinear	LSTM-Seq2Seq	Otros
Ventana L	48 / 168 / 336	0.958 / 0.883 / **0.862**	1.035 / **1.014** / 1.077	MLP: 0.839 / – / 0.824
Historia	3 / 12 / 30 meses	0.887 / 0.891 / 0.883	1.264 / 1.088 / 1.014	LightGBM 0.912 / 0.847 / 0.842; PatchTST 0.934 / 0.956 / 0.946
Normalización	serie / global / ventana	0.883 / 1.171 / 0.887	1.014 / 1.752 / 1.066	
LSTM	oculto 64 / 256; 1 capa		1.156 / 1.030; 1.267	dropout 0.3: 1.095; lr 3e-3: 1.047
Estrategia (40 ep.)	AR / MIMO / enc-dec / enc-dec+TF		1.004 / 0.997 / **0.971** / 1.022	MLP L=336, 60 ep.: **0.818**

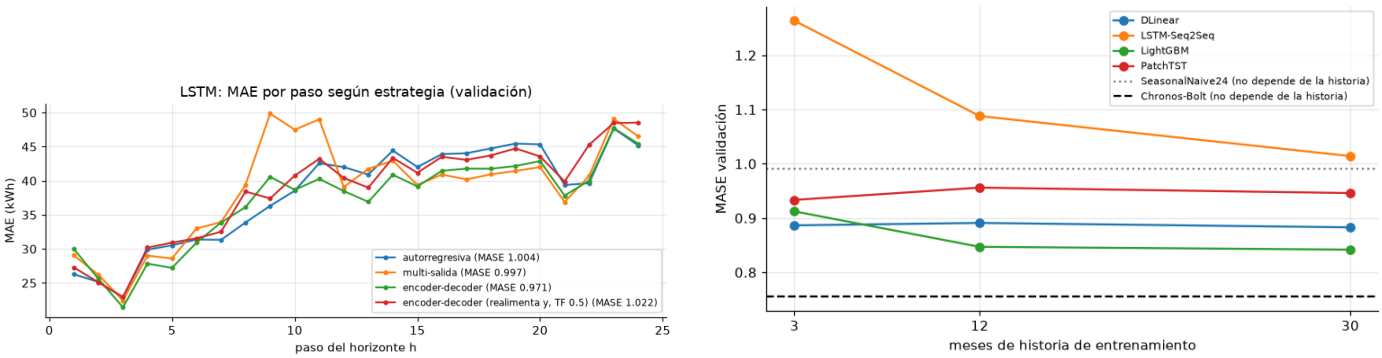


Figura 2: Izq.: MAE por paso de las tres estrategias con la misma LSTM. Der.: MASE contra meses de historia (validación), con Chronos y el seasonal naive como referencia.

5. Comparación de todos los modelos (prueba, 92 orígenes, 100 clientes)

Cuadro 2: Ordenada por MASE. Hardware: Apple M4 Pro, 24 GB (PyTorch y Chronos en MPS; NeuralForecast, LightGBM y StatsForecast en CPU). Tiempos en segundos. "Xmas" = MASE en la semana del 22 al 28 de diciembre. H168 = MASE con $H = 168$ (86 orígenes).

Modelo	Familia	L	Estrategia	Cov.	Parám.	Entr.	Infer.	MAE	RMSE	WAPE	MASE	H168	Xmas
Chronos-Bolt (base)	Fundacional	2048	multi-salida	No	205 M	–	65.9	30.4	201.2	.059	**0.737**	0.917	1.34
iTransformer	Atención	168	multi-salida	No	1.10 M	507	1.1	33.1	162.2	.064	**0.803**		1.28
LightGBM	Árboles	lags	recursiva	Sí	1997 árb.	105	4.7	32.6	163.7	.063	0.810		1.41
MLP (propio)	MLP/lineal	336	multi-salida	Sí	546 k	14	0.1	33.2	169.8	.064	0.819	0.993	1.46
N-HiTS	Residual	168	multi-salida	Sí	3.84 M	1558	1.7	34.8	168.2	.068	0.848		1.40
DLinear (propio)	MLP/lineal	336	multi-salida	No	16 k	11	0.1	34.7	180.8	.067	0.866	0.984	1.82
NLinear (propio)	MLP/lineal	336	multi-salida	No	8 k	7	0.1	34.8	181.2	.067	0.868	0.994	1.82
TCN	Convolucional	168	multi-salida	Sí	254 k	3646	12.9	35.5	170.1	.069	0.875		1.59
PatchTST	Atención	168	multi-salida	No	445 k	2762	2.2	37.8	187.9	.073	0.916		1.77
MSTL	Baseline	8 sem.	directa	No	–	284 (ajuste+pron.)		36.4	195.9	.071	0.929		2.06
LSTM-Seq2Seq (propio)	Enc.-dec.	168	enc.-dec.	Sí	406 k	204	0.7	39.6	189.6	.077	0.939		1.47
LSTM-MIMO (propio)	Recurrente	168	multi-salida	Sí	247 k	178	0.8	40.4	190.1	.078	0.964		1.56
LSTM-AR (propio)	Recurrente	168	autorreg.	Sí	203 k	197	0.7	40.6	189.6	.079	0.976		1.55
Seasonal naive 24	Baseline	24	directa	No	0	0	<1	44.1	232.2	.086	1.034	1.214	2.17
Seasonal naive 168	Baseline	168	directa	No	0	0	<1	39.7	182.4	.077	1.114	1.119	1.60
DeepAR	Probabilístico	168	AR (muestreo)	Sí	204 k	556	11.3	51.6	210.4	.100	1.325		1.99
Naive	Baseline	1	directa	No	0	0	<1	158.6	504.7	.308	3.989		3.91

Probabilísticos (P10/P50/P90): Chronos-Bolt obtuvo pinball 10.58 y cobertura P10–P90 de **79.8 %** (nominal 80 %). DeepAR obtuvo pinball 18.36 y cobertura 55.3 %: sus intervalos son demasiado angostos y su error crece con h (MASE por paso de 0.78 a 1.58). DeepAR se entrenó con 24 meses y 2500 pasos sin validación interna, porque esa validación muestrea 100 trayectorias por ventana y agotaba la RAM.

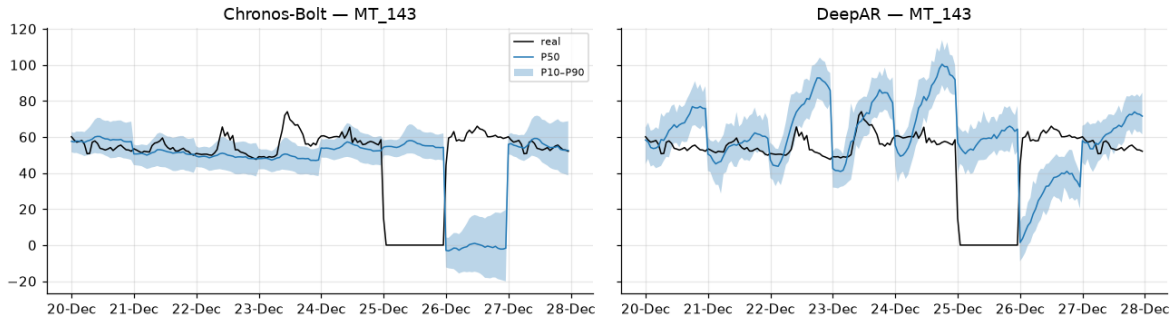


Figura 3: Pronóstico P50 e intervalo P10–P90 del 20 al 27 de diciembre para el cliente mediano: Chronos-Bolt (izq.) y DeepAR (der.).

Reentrenamiento mensual (1 de oct, nov y dic, ventana expandible): iTransformer pasó de 0.803 a 0.818 y LightGBM de 0.810 a 0.805. No cambia más allá del ruido. MSTL no se repite: StatsForecast ya lo reajusta en cada origen. **Semillas** (42, 43, 44): iTransformer 0.812 ± 0.010 y MLP 0.812 ± 0.007. **Local vs. global** (MLP, 10 clientes): local 0.911 contra **global 0.858**.

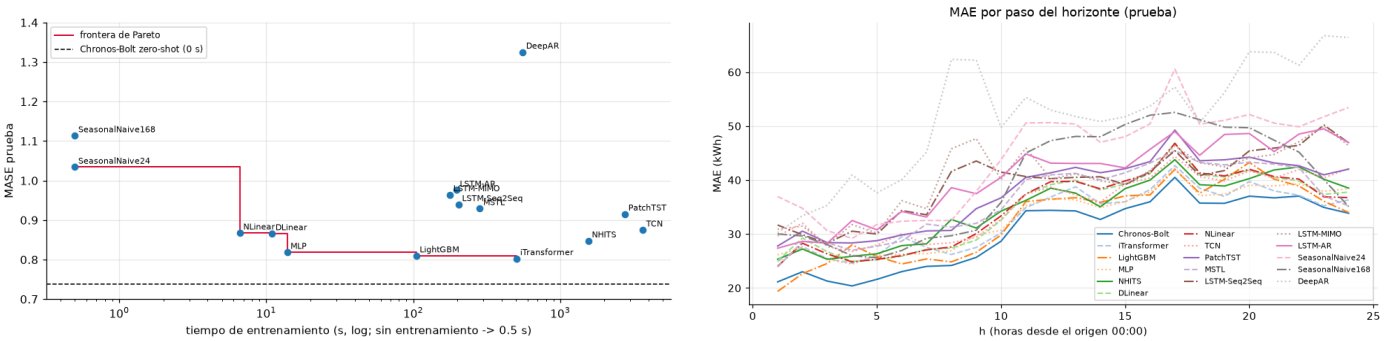


Figura 4: Izq.: MASE contra tiempo de entrenamiento (log) y frontera de Pareto: SNaive24 → NLinear → DLinear → MLP → LightGBM → iTransformer. Der.: MAE por paso del horizonte; como el origen es a las 00:00, h coincide con la hora del día.

6. Discusión y conclusiones

Ganador. Chronos-Bolt zero-shot (0.737) fue 29 % mejor que el seasonal naive de 24 h. Entre los modelos entrenados, iTransformer (0.803), LightGBM (0.810) y el MLP (0.819) empatan dentro de la variación por semilla ($\pm$0.01). Para producción la mejora de $\sim$22 % sobre el naive justifica un modelo, pero uno barato: LightGBM o el MLP están en la frontera de Pareto (14–105 s de entrenamiento), mientras N-HiTS y TCN cuestan 26–61 min sin ganar precisión.

DLinear vs. Transformers. Se replica en parte. Con $H = 24$, DLinear y NLinear (8–16 k parámetros) superan a PatchTST (0.916) y MSTL, pero no a iTransformer, que aprovecha la correlación entre clientes. Con $H = 168$ los lineales (0.98–0.99) siguen a la par del MLP.

Multi-paso. El encoder–decoder con calendario en el decoder fue el mejor (prueba 0.939, contra 0.964 de MIMO y 0.976 de AR). La AR es la mejor en $h = 1$ (0.66), pero a partir de $h \approx 9$–12 acumula errores (1.11 contra 1.02). Realimentar y con teacher forcing empeoró el resultado (*exposure bias*). En todas las familias el error sube con h y con la carga de 14 a 19 h.

L, normalización e historia. Una L larga ayuda a los modelos lineales y al MLP, pero no a la LSTM. La normalización global es la peor. La historia es clave para la LSTM (1.26 → 1.01) y para LightGBM (0.91 → 0.84), y casi irrelevante para DLinear y PatchTST. Con 3 meses DLinear supera a LightGBM; desde 12 meses LightGBM supera a DLinear, la LSTM y PatchTST, y solo el MLP con 30 meses (0.818 en validación) y iTransformer lo superan.

Global. El modelo global gana (0.858 contra 0.911), sobre todo en clientes ruidosos o con cambios de régimen (MT_247, MT_268, MT_319 y MT_360: 11–14 %).

Chronos quedó por delante de todos y con cuantiles calibrados. Lo usaríamos en arranque en frío, con muchas series heterogéneas o como baseline fuerte. Un modelo propio conviene si hay covariables exclusivas (clima, tarifas) o restricciones de costo de inferencia.

Navidad. Todos los modelos empeoran en la semana del 22 al 28 de diciembre (MASE $\times$1.4–2.2). Los que usan calendario o feriado (iTransformer 1.28, Chronos 1.34, LightGBM 1.41) degradan bastante menos que DLinear (1.82), MSTL (2.06) o el seasonal naive de 24 h (2.17). La covariable de feriado ayuda, pero con solo dos Navidades de entrenamiento el cambio de régimen sigue dominando el error.

Semilla. La desviación estándar del MASE es de 0.007 a 0.010, así que diferencias menores a $\sim$0.02 no son concluyentes.

Repositorio: `https://github.com/FerAHMz/lab9-dl`. Contiene el notebook ejecutado, los scripts `src/01–07`, `results/` y `results/forecasts_test.csv.gz` con 3.75 M filas (`unique_id, ds, modelo, y_hat`).